

尚硅谷大数据技术之 Azkaban

(作者: 尚硅谷大数据研发部)

版本:V3.84.4

第1章 Azkaban 概论

1.1 为什么需要工作流调度系统

- 1) 一个完整的数据分析系统通常都是由大量任务单元组成: Shell 脚本程序,Java 程序,MapReduce 程序、Hive 脚本等
- 2) 各任务单元之间存在时间先后及前后依赖关系
- 3) 为了很好地组织起这样的复杂执行计划,需要一个工作流调度系统来调度执行;



为什么需要工作流调度系统





让天下没有难学的技术

1.2 常见工作流调度系统

- 1) 简单的任务调度:直接使用 Linux 的 Crontab 来定义;
- 2)复杂的任务调度:开发调度平台或使用现成的开源调度系统,比如 Ooize、Azkaban、Airflow、DolphinScheduler等。

1.3 Azkaban 与 Oozie 对比

总体来说,Ooize 相比 Azkaban 是一个重量级的任务调度系统,功能全面,但配置使用也更复杂。如果可以不在意某些功能的缺失,轻量级调度器 Azkaban 是很不错的候选对象。



第2章 Azkaban入门

2.1 集群模式安装

2.1.1 上传 tar 包

1) 将 azkaban-db-3.84.4.tar.gz, azkaban-exec-server-3.84.4.tar.gz, azkaban-web-server-3.84.4.tar.gz 上传到 hadoop102 的/opt/software 路径

```
[atguigu@hadoop102 software]$ 11
总用量 35572
-rw-r--r-. 1 atguigu atguigu 6433 4月 18 17:24 azkaban-db-3.84.4.tar.gz
-rw-r--r-. 1 atguigu atguigu 16175002 4月 18 17:26 azkaban-exec-server-3.84.4.tar.gz
-rw-r--r-. 1 atguigu atguigu 20239974 4月 18 17:26 azkaban-web-server-3.84.4.tar.gz
```

2) 新建/opt/module/azkaban 目录,并将所有 tar 包解压到这个目录下

[atguigu@hadoop102 software]\$ mkdir /opt/module/azkaban

3) 解压 azkaban-db-3.84.4.tar.gz、 azkaban-exec-server-3.84.4.tar.gz 和 azkaban-web-server-3.84.4.tar.gz 到/opt/module/azkaban 目录下

```
[atguigu@hadoop102 software]$ tar -zxvf azkaban-db-3.84.4.tar.gz - C /opt/module/azkaban/
[atguigu@hadoop102 software]$ tar -zxvf azkaban-exec-server-3.84.4.tar.gz -C /opt/module/azkaban/
[atguigu@hadoop102 software]$ tar -zxvf azkaban-web-server-3.84.4.tar.gz -C /opt/module/azkaban/
```

4) 进入到/opt/module/azkaban 目录,依次修改名称

```
[atguigu@hadoop102 azkaban]$ mv azkaban-exec-server-3.84.4/
azkaban-exec
[atguigu@hadoop102 azkaban]$ mv azkaban-web-server-3.84.4/
azkaban-web
```

2.1.2 配置 MySQL

1)正常安装 MySQL

详见《尚硅谷大数据技术之 Hive》

2) 启动 MySQL

[atguigu@hadoop102 azkaban]\$ mysql -uroot -p000000

3) 登陆 MySQL, 创建 Azkaban 数据库

mysql> create database azkaban;

4) 创建 azkaban 用户并赋予权限

设置密码有效长度 4 位及以上

mysql> set global validate password length=4;

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问:尚硅谷官网



设置密码策略最低级别

mysql> set global validate password policy=0;

创建 Azkaban 用户,任何主机都可以访问 Azkaban,密码是 000000

mysql> CREATE USER 'azkaban'@'%' IDENTIFIED BY '000000';

赋予 Azkaban 用户增删改查权限

mysql> GRANT SELECT, INSERT, UPDATE, DELETE ON azkaban.* to
'azkaban'@'%' WITH GRANT OPTION;

5) 创建 Azkaban 表,完成后退出 MySQL

```
mysql> use azkaban;
mysql> source /opt/module/azkaban/azkaban-db-3.84.4/create-all-
sql-3.84.4.sql
mysql> quit;
```

6) 更改 MySQL 包大小; 防止 Azkaban 连接 MySQL 阻塞

[atguigu@hadoop102 software]\$ sudo vim /etc/my.cnf

在[mysqld]下面加一行 max allowed packet=1024M

```
[mysqld]
max_allowed_packet=1024M
```

8) 重启 MySQL

[atguigu@hadoop102 software]\$ sudo systemctl restart mysqld

2.1.3 配置 Executor Server

Azkaban Executor Server 处理工作流和作业的实际执行。

1) 编辑 azkaban. properties

[atguigu@hadoop102 azkaban]\$ vim /opt/module/azkaban/azkaban-exec/conf/azkaban.properties

修改如下标红的属性

```
#...
default.timezone.id=Asia/Shanghai
#...
azkaban.webserver.url=http://hadoop102:8081

executor.port=12321
#...
database.type=mysql
mysql.port=3306
mysql.host=hadoop102
mysql.database=azkaban
mysql.user=azkaban
mysql.user=azkaban
mysql.password=000000
mysql.numconnections=100
```

2) 同步 azkaban-exec 到所有节点

[atguigu@hadoop102 azkaban]\$ xsync /opt/module/azkaban/azkaban-exec

3)必须进入到/opt/module/azkaban/azkaban-exec 路径,分别在三台机器上,启动 executor

server

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问:尚硅谷官网



```
[atguigu@hadoop102 azkaban-exec]$ bin/start-exec.sh
[atguigu@hadoop103 azkaban-exec]$ bin/start-exec.sh
[atguigu@hadoop104 azkaban-exec]$ bin/start-exec.sh
```

注意:如果在/opt/module/azkaban/azkaban-exec 目录下出现 executor.port 文件,说明 启动成功

4) 下面激活 executor, 需要

```
[atguigu@hadoop102 azkaban-exec]$ curl -G
"hadoop102:12321/executor?action=activate" && echo

[atguigu@hadoop103 azkaban-exec]$ curl -G
"hadoop103:12321/executor?action=activate" && echo

[atguigu@hadoop104 azkaban-exec]$ curl -G
"hadoop104:12321/executor?action=activate" && echo
```

如果三台机器都出现如下提示,则表示激活成功

{"status": "success"}

2.1.4 配置 Web Server

Azkaban Web Server 处理项目管理,身份验证,计划和执行触发。

1) 编辑 azkaban. properties

 $[atguigu@hadoop102 \quad azkaban] \$ \quad vim \quad /opt/module/azkaban/azkaban-web/conf/azkaban.properties$

修改如下属性

```
default.timezone.id=Asia/Shanghai
...
database.type=mysql
mysql.port=3306
mysql.host=hadoop102
mysql.database=azkaban
mysql.user=azkaban
mysql.user=azkaban
mysql.password=000000
mysql.numconnections=100
...
azkaban.executorselector.filters=StaticRemainingFlowSize,CpuStatu
s
```

说明:

#StaticRemainingFlowSize: 正在排队的任务数;

#CpuStatus: CPU 占用情况

#MinimumFreeMemory: 內存占用情况。测试环境,必须将 MinimumFreeMemory 删除掉,否则它会认为集群资源不够,不执行。

2) 修改 azkaban-users. xml 文件,添加 atguigu 用户

[atguigu@hadoop102 azkaban-web]\$ vim /opt/module/azkaban/azkabanweb/conf/azkaban-users.xml

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问:尚硅谷官网



```
<azkaban-users>
  <user groups="azkaban" password="azkaban" roles="admin"
username="azkaban"/>
  <user password="metrics" roles="metrics" username="metrics"/>
    <user password="atguigu" roles="admin" username="atguigu"/>
    <role name="admin" permissions="ADMIN"/>
    <role name="metrics" permissions="METRICS"/>
  </azkaban-users>
```

- 3) 必须进入到 hadoop102 的/opt/module/azkaban/azkaban-web 路径,启动 web server [atguigu@hadoop102 azkaban-web]\$ bin/start-web.sh
- 4) 访问 http://hadoop102:8081, 并用 atguigu 用户登陆

2.2 Work Flow 案例实操

2.2.1 HelloWorld 案例

1) 在 windows 环境,新建 azkaban. project 文件,编辑内容如下

azkaban-flow-version: 2.0

注意:该文件作用,是采用新的Flow-API方式解析 flow文件。

2) 新建 basic. flow 文件,内容如下

nodes:


- name: jobA
 type: command
 config:

command: echo "Hello World"

- (1) Name: job 名称
- (2) Type: job 类型。command 表示你要执行作业的方式为命令
- (3) Config: job 配置
- 3)将 azkaban. project、basic. flow 文件压缩到一个 zip 文件,文件名称必须是英文。



4) 在 WebServer 新建项目: http://hadoop102:8081/index

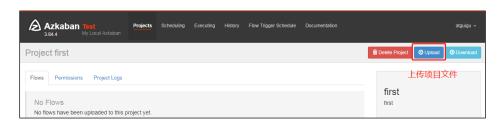


5) 给项目名称命名和添加项目描述





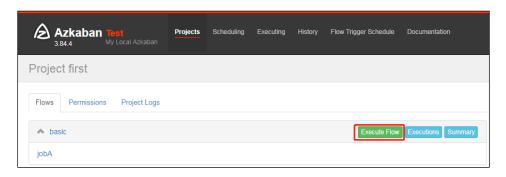
6) first. zip 文件上传



7) 选择上传的文件



8) 执行任务流











9) 在日志中,查看运行结果







2.2.2 作业依赖案例

需求: JobA 和 JobB 执行完了,才能执行 JobC

具体步骤:

1) 修改 basic.flow 为如下内容

```
nodes:
  - name: jobC
   type: command
   # jobC 依赖 JobA 和 JobB
   dependsOn:
     - jobA
     - jobB
   config:
     command: echo "I'm JobC"
  - name: jobA
   type: command
   config:
     command: echo "I'm JobA"
 - name: jobB
   type: command
   config:
     command: echo "I'm JobB"
```

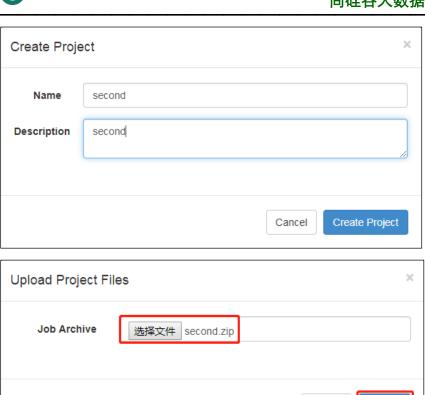
- (1) depends0n: 作业依赖,后面案例中演示
- 2) 将修改后的 basic.flow 和 azkaban.project 压缩成 second.zip 文件

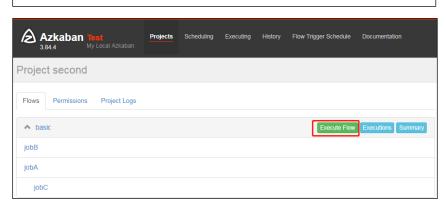


3) 重复 2.3.1 节 HelloWorld 后续步骤。

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网

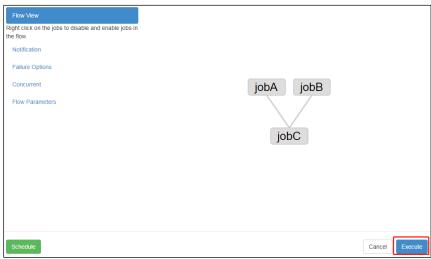







Cancel


Upload



更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网







2.2.3 自动失败重试案例

需求:如果执行任务失败,需要重试3次,重试的时间间隔10000ms

具体步骤:

1)编译配置流

nodes: name: JobA type: command config: command: sh /not_exists.sh retries: 3 retry.backoff: 10000

参数说明:

retries: 重试次数

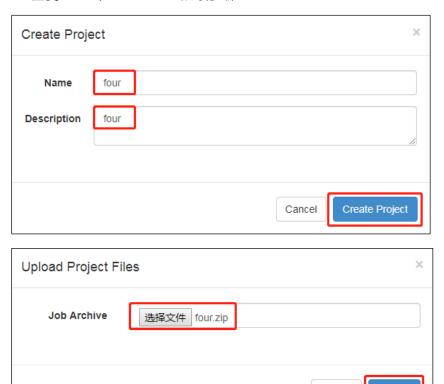
retry.backoff: 重试的时间间隔

2) 将修改后的 basic.flow 和 azkaban.project 压缩成 four.zip 文件





3) 重复 2.3.1 节 HelloWorld 后续步骤。



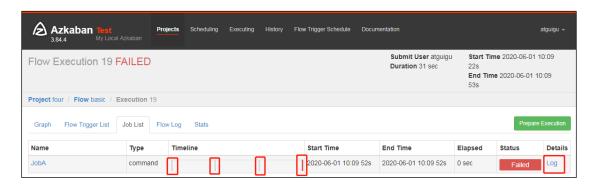


Cancel

Upload

4) 执行并观察到一次失败+三次重试





5) 也可以点击上图中的 Log, 在任务日志中看到, 总共执行了 4次。



6) 也可以在 Flow 全局配置中添加任务失败重试配置,此时重试配置会应用到所有 Job。

案例如下:

```
config:
   retries: 3
   retry.backoff: 10000
nodes:
   - name: JobA
   type: command
   config:
      command: sh /not_exists.sh
```

2.2.4 手动失败重试案例

需求: JobA=》JobB(依赖于 A)=》JobC=》JobD=》JobE=》JobF。生产环境,任何 Job 都有可能挂掉,可以根据需求执行想要执行的 Job。

具体步骤:

1)编译配置流

```
nodes:
    name: JobA
    type: command
    config:
        command: echo "This is JobA."
        name: JobB
```

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网

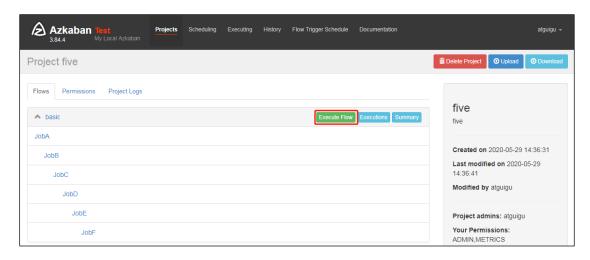


```
type: command
 dependsOn:
   - JobA
 config:
   command: echo "This is JobB."
- name: JobC
 type: command
 dependsOn:
   - JobB
 config:
   command: echo "This is JobC."
- name: JobD
 type: command
 dependsOn:
   - JobC
 config:
   command: echo "This is JobD."
- name: JobE
 type: command
 dependsOn:
   - JobD
 config:
   command: echo "This is JobE."
- name: JobF
 type: command
 dependsOn:
   - JobE
 config:
   command: echo "This is JobF."
```

2) 将修改后的 basic.flow 和 azkaban.project 压缩成 five.zip 文件

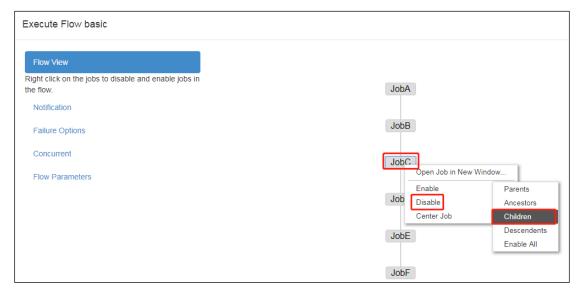


3) 重复 2.3.1 节 HelloWorld 后续步骤。



更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问:尚硅谷官网







Enable 和 Disable 下面都分别有如下参数:

Parents: 该作业的上一个任务

Ancestors: 该作业前的所有任务

Children: 该作业后的一个任务

Descendents: 该作业后的所有任务

Enable All: 所有的任务

4) 可以根据需求选择性执行对应的任务。





第3章 Azkaban 进阶

3.1 JavaProcess 作业类型案例

JavaProcess 类型可以运行一个自定义主类方法,type 类型为 javaprocess,可用的配置为:

Xms: 最小堆

Xmx: 最大堆

classpath: 类路径

java.class: 要运行的 Java 对象, 其中必须包含 Main 方法

main.args: main 方法的参数

案例:

- 1) 新建一个 azkaban 的 maven 工程
- 2) 创建包名: com.atguigu
- 3) 创建 AzTest 类

```
package com.atguigu;

public class AzTest {
    public static void main(String[] args) {
        System.out.println("This is for testing!");
    }
}
```

- 4) 打包成 jar 包 azkaban-1.0-SNAPSHOT.jar
- 5) 新建 testJava.flow,内容如下

```
nodes:
  - name: test_java
  type: javaprocess
  config:
```



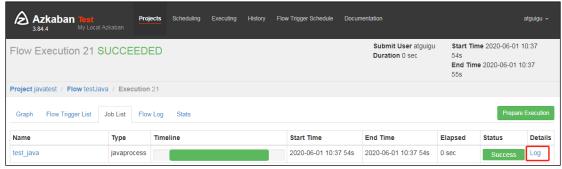
Xms: 96M Xmx: 200M

java.class: com.atguigu.AzTest


- 6)将 Jar 包、flow 文件和 project 文件打包成 javatest.zip
- 7) 创建项目=》上传 javatest.zip =》执行作业=》观察结果











3.2 条件工作流案例

条件工作流功能允许用户自定义执行条件来决定是否运行某些Job。条件可以由当前Job 的父 Job 输出的运行时参数构成,也可以使用预定义宏。在这些条件下,用户可以在确定 Job 执行逻辑时获得更大的灵活性,例如,只要父 Job 之一成功,就可以运行当前 Job。

3.2.1 运行时参数案例

- 1) 基本原理
 - (1) 父 Job 将参数写入 JOB OUTPUT PROP FILE 环境变量所指向的文件
 - (2) 子 Job 使用 \${jobName:param}来获取父 Job 输出的参数并定义执行条件
- 2) 支持的条件运算符:
 - (1) == 等于
 - (2)!= 不等于
 - (3) > 大于
 - (4) >= 大于等于
 - (5) < 小于
 - (6) <= 小于等于
 - (7) && 与
 - (8) || 或
 - (9)! 非
- 3) 案例:

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网



需求:

JobA 执行一个 shell 脚本。

JobB 执行一个 shell 脚本,但 JobB 不需要每天都执行,而只需要每个周一执行。

(1) 新建 JobA.sh

```
#!/bin/bash
echo "do JobA"
wk=`date +%w`
echo "{\"wk\":$wk}" > $JOB_OUTPUT_PROP_FILE
```

(2) 新建 JobB.sh


```
#!/bin/bash
echo "do JobB"
```

(3) 新建 condition.flow

```
nodes:
- name: JobA
  type: command
  config:
     command: sh JobA.sh

- name: JobB
  type: command
  dependsOn:
     - JobA
  config:
     command: sh JobB.sh
  condition: ${JobA:wk} == 1
```

- (4) 将 JobA.sh、JobB.sh、condition.flow 和 azkaban.project 打包成 condition.zip
- (5) 创建 condition 项目=》上传 condition.zip 文件=》执行作业=》观察结果
- (6) 按照我们设定的条件, JobB 会根据当日日期决定是否执行。



3.2.2 预定义宏案例

Azkaban 中预置了几个特殊的判断条件, 称为预定义宏。

预定义宏会根据所有父 Job 的完成情况进行判断,再决定是否执行。可用的预定义宏如下:

- (1) all success: 表示父 Job 全部成功才执行(默认)
- (2) all_done: 表示父 Job 全部完成才执行

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



- (3) all_failed:表示父 Job 全部失败才执行
- (4) one success: 表示父 Job 至少一个成功才执行
- (5) one_failed:表示父 Job 至少一个失败才执行

1) 案例

需求:

JobA 执行一个 shell 脚本

JobB 执行一个 shell 脚本

JobC 执行一个 shell 脚本,要求 JobA、JobB 中有一个成功即可执行

(1) 新建 JobA.sh

```
#!/bin/bash
echo "do JobA"
```

(2) 新建 JobC.sh

```
#!/bin/bash
echo "do JobC"
```

(3) 新建 macro.flow


```
nodes:
- name: JobA
  type: command
  config:
    command: sh JobA.sh
 - name: JobB
  type: command
  config:
    command: sh JobB.sh
- name: JobC
  type: command
  dependsOn:
    - JobA
    - JobB
  config:
    command: sh JobC.sh
  condition: one success
```

(4) JobA.sh、JobC.sh、macro.flow、azkaban.project 文件, 打包成 macro.zip。

注意:没有 JobB.sh。

(5) 创建 macro 项目=》上传 macro.zip 文件=》执行作业=》观察结果





3.3 定时执行案例

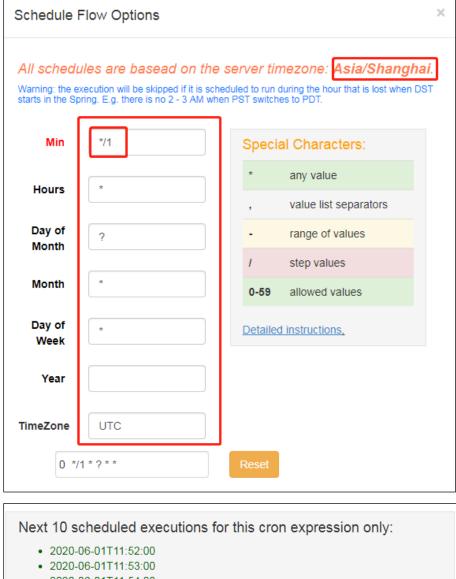
需求: JobA 每间隔 1 分钟执行一次; 具体步骤:

1) Azkaban 可以定时执行工作流。在执行工作流时候,选择左下角 Schedule




2) 右上角注意时区是上海,然后在左面填写具体执行事件,填写的方法和 crontab 配置定时任务规则一致。

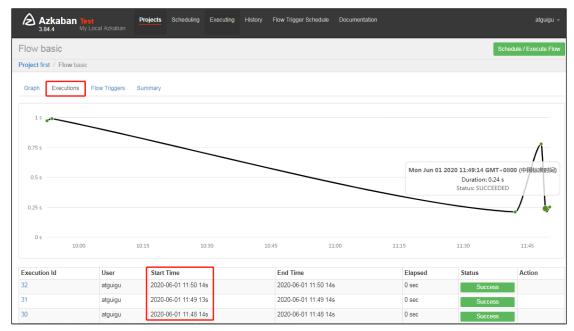




3) 观察结果








4) 删除定时调度

点击 remove Schedule 即可删除当前任务的调度规则。



3.4 邮件报警案例

3.4.1 注册邮箱

- 1) 申请注册一个 126 邮箱
- 2) 点击邮箱账号=》账号管理





3) 开启 SMTP 服务



4) 一定要记住授权码



3.4.2 默认邮件报警案例

Azkaban 默认支持通过邮件对失败的任务进行报警,配置方法如下:

1) 在 azkaban-web 节 点 hadoop102 上 , 编 辑 /opt/module/azkaban/azkaban-web/conf/azkaban.properties,修改如下内容:

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



[atguigu@hadoop102 azkaban-web]\$ vim /opt/module/azkaban/azkaban-web/conf/azkaban.properties

添加如下内容:

#这里设置邮件发送服务器,需要 申请邮箱,切开通 stmp 服务,以下只是例子 mail.sender=atguigu@126.com mail.host=smtp.126.com mail.user=atguigu@126.com mail.password=用邮箱的授权码

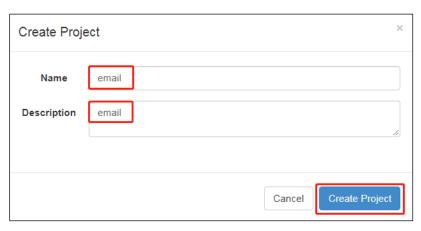
2) 保存并重启 web-server。

[atguigu@hadoop102 azkaban-web]\$ bin/shutdown-web.sh
[atguigu@hadoop102 azkaban-web]\$ bin/start-web.sh

3) 编辑 basic.flow


```
nodes:
  - name: jobA
  type: command
  config:
    command: echo "This is an email test."
```

- 4) 将 azkaban.project 和 basic.flow 压缩成 email.zip
- 5) 创建工程=》上传文件=》执行作业=》查看结果










6) 观察邮箱,发现执行成功或者失败的邮件



3.5 电话报警案例

3.5.1 第三方告警平台集成

有时任务执行失败后邮件报警接收不及时,因此可能需要其他报警方式,比如电话报警。 如有类似需求,可与第三方告警平台进行集成,例如睿象云。

1) 进入睿象云官网注册账号并登录

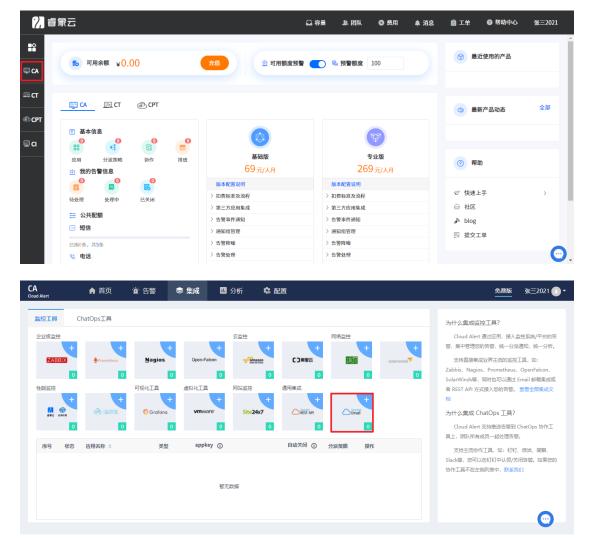
更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



官网地址: https://www.aiops.com/



2) 集成告警平台,使用 Email 集成



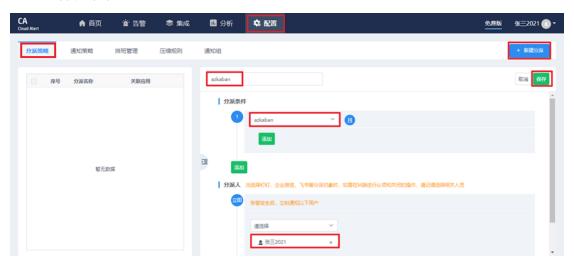
3) 获取邮箱地址,后边需将报警信息发送至该邮箱

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网






4) 配置分派策略



5) 配置通知策略








3.5.2 测试

执行上一个邮件通知的案例,将通知对象改为刚刚集成第三方平台时获取的邮箱。



3.6 Azkaban 多 Executor 模式注意事项

Azkaban 多 Executor 模式是指,在集群中多个节点部署 Executor。在这种模式下,Azkaban web Server 会根据策略,选取其中一个 Executor 去执行任务。

为确保所选的 Executor 能够准确的执行任务,我们须在以下两种方案任选其一,推荐使用方案二。

方案一: 指定特定的 Executor (hadoop102) 去执行任务。

1) 在 MySQL 中 azkaban 数据库 executors 表中,查询 hadoop102 上的 Executor 的 id。 更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问:尚硅谷官网



2) 在执行工作流程时加入 useExecutor 属性,如下



方案二:在 Executor 所在所有节点部署任务所需脚本和应用。

第4章 参考资料

4.1 Azkaban 完整配置

见官网文档: https://azkaban.readthedocs.io/en/latest/configuration.html

4.2 YAML 语法

Azkaban2.0 工作流文件是用 YAML 语法写的,相关教程如下:



YAML语法简易入门.mhtml