

大数据技术图解

尚硅谷大数据研究院



为什么选用Flume

Python爬虫数据

Java后台日志数 据 服务器本地磁盘 文件夹

上传文件到HDFS,但是不实时。 且读取速度和向HDFS写数据的 速度很难匹配。没有缓存处理。

HDFS

Flume

Flume最主要的作用就是,实时读取服务器本地磁盘的数据,将数据写入到HDFS。

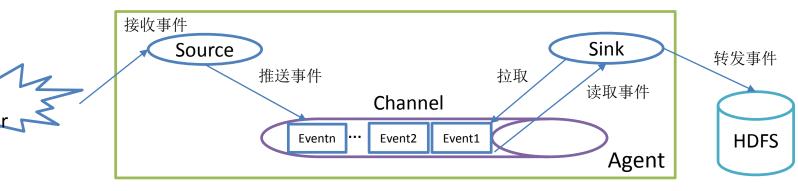


数据输入端

Flume组成架构

Flume流式处理

数据输出端



Source数据输入端的类型有: avro、thrift、exec、jms、spooling directory、netcat、sequence generator、syslog、http、legacy等。但是目前在企业中使用最广泛的就是日志文件。

Channel是位于Source和Sink之间的缓冲区。

Flume自带两种Channel: Memory Channel和File Channel。 Memory Channel是基于内存缓存,在不需要关心数据丢失的情景下适用。

File Channel是Flume的持久化Channel。系统宕机不会丢失数据。

Sink组件目的地包 ihdfs、kafka、logger

括hdfs、kafka、logger、avro、thrift、ipc、file、null、HBase、solr、自定义。但是目前在企业中使用最广泛的是HDFS和Kafka。

尚硅谷 Flume Agent内部原理 1接收事件 3 将事件传递给拦截器链 Source 拦截器1 2 处理事件 4 将每个事件给Channel选择器 Channel Channel 拦截器2 选择器 处理器 5返回写入事件Channel列表 拦截器3 6根据Channel选择器 的选择结果,将事件 写入相应Channel。 Channel2 Channel3 Channel1 Sink处理器 7 Sink处理器选择其中一个 Sink去获取Channel数据,并将 Sink1 Sink2 Sink3 获取数据写入到下一个阶段。



监听数据端口案例分析

1 通过telnet工具向 localhost主机的44444端 口发送数据 2 Flume监控localhost 主机的44444端口数据。 通过Flume的source端 读取数据。 3 Flume将获取的数据通过Sink端写出到控制台

\$ telnet localhost

44444

\$ bin/flume-ng agent --conf conf/

--name a1

--conf-file job/flume-telnet.conf

-Dflume.root.logger==INFO,console

Last login: Sun May 20 10:40:29 2018 from 192.168.1.^
[atguigu@hadoop102 ~]\$ telnet localhost 44444
Trying ::1...
telnet: connect to address ::1: Connection refused
Trying 127.0.0.1...
Connected to localhost.
Escape character is '^]'.
hello
OK

```
Dhadoop102

2018-05-20 10:43:08,131 (lifecycleSupervisor-1-2) [1 ource.java:169)] Created serverSocket:sun.nio.ch.Ser

2018-05-20 10:44:10,130 (SinkRunner-PollingRunner-DefaultSinkProcessor) [INFO - org.apache.flume.sink.LoggerSink.process(LoggerSink.java:95)] Event: { headers:{} body: 68 65 6C 6C 6F 0D hello.}
```



配置文件解析

```
# Name the components on this agent
                                                 a1:表示agent的名称
a1.sources = r1 r1:表示a1的输入源
a1.sinks = k1 k1:表示a1的输出目的地
al.channels = cl cl:表示al的缓冲区
# Describe/configure the source
al.sources.rl.type = netcat
                               表示a1的输入源类型为netcat类型
al.sources.rl.bind = localhost
                               表示a1的监听的主机
al.sources.rl.port = 44444
                               表示a1的监听的端口号
# Describe the sink
                               表示a1的输出目的地是logger类型
al.sinks.kl.type = logger
# Use a channel which buffers events in memory
a1.channels.c1.type = memory
                                        表示a1的channel类型是memory内存型
al.channels.cl.capacity = 1000
                                        表示a1的channel总容量1000
al.channels.cl.transactionCapacity = 100
                                        表示a1的channel传输总容量100
# Bind the source and sink to the channel
al.sources.rl.channels = c1
                              表示将r1和c1连接起来
a1.sinks.k1.channel = c1
                              表示将k1和c1连接起来
```



实时读取本地文件到HDFS案例

Hive实时更新日志

3 开启Hive, 生成日志

> Hive日志文件 /opt/module/hive/lo gs/hive.log

Exec Source HDFS Sink Flume监控文件

Memory Channel

- 1 创建符合条件的flume配置文件
- 2 执行配置文件, 开启监控

4 查看HDFS 上数据

HDFS



a2. sinks. k2. hdfs. minBlockReplicas = 1

实时读取本地文件到HDFS案例

```
# Name the components on this agent
a2. sources = r2
                          #定义source
                          #定义sink
a2. sinks = k2
a2. channels = c2
                          #定义channel
# Describe/configure the source
a2. sources. r2. type = exec #定义source类型为exec可执行命令的
a2. sources. r2. command = tail -F /opt/module/hive/logs/hive. log
a2. sources. r2. shell = /bin/bash -c #执行shell脚本的绝对路径
# Describe the sink
a2. sinks. k2. type = hdfs
a2. sinks. k2. hdfs. path = hdfs://hadoop102:9000/flume/%Y%m%d/%H
a2. sinks. k2. hdfs. filePrefix = logs-
                                       #上传文件的前缀
                                       #是否按照时间滚动文件夹
a2. sinks. k2. hdfs. round = true
                                       #多少时间单位创建一个新的文件夹 #重新定义时间单位
a2. sinks. k2. hdfs. roundValue = 1
a2. sinks. k2. hdfs. roundUnit = hour
a2. sinks. k2. hdfs. useLocalTimeStamp = true #是否使用本地时间戳
                                       #积攒多少个Event才flush到HDFS一次
a2. sinks. k2. hdfs. batchSize = 1000
a2. sinks. k2. hdfs. fileType = DataStream
                                       #设置文件类型,可支持压缩
a2. sinks, k2. hdfs, rollInterval = 600
                                       #多久生成一个新的文件
                                       #设置每个文件的滚动大小
a2. sinks. k2. hdfs. rollSize = 134217700
a2. sinks. k2. hdfs. rollCount = 0
                                       #文件的滚动与Event数量无关
```

#最小冗余数

Use a channel which buffers events in memory a2. channels. c2. type = memory a2. channels. c2. capacity = 1000 a2. channels. c2. transactionCapacity = 100

Bind the source and sink to the channel a2. sources. r2. channels = c2 a2. sinks. k2. channel = c2



实时读取目录文件到HDFS案例

待上传的文件

3 向upload目录中添加文件

被监控的目录 /opt/module/flume/ upload Spooldir Source HDFS Sink Flume监控目录

Memory Channel

- 1 创建符合条件的flume配置文件
- 2 执行配置文件, 开启监控

5 查看/opt/module/flume/upload 目录中上传的文件是否已经标记 为.COMPLETED结尾;.tmp后缀结 尾文件没有上传。 4 查看HDFS 上数据

HDFS

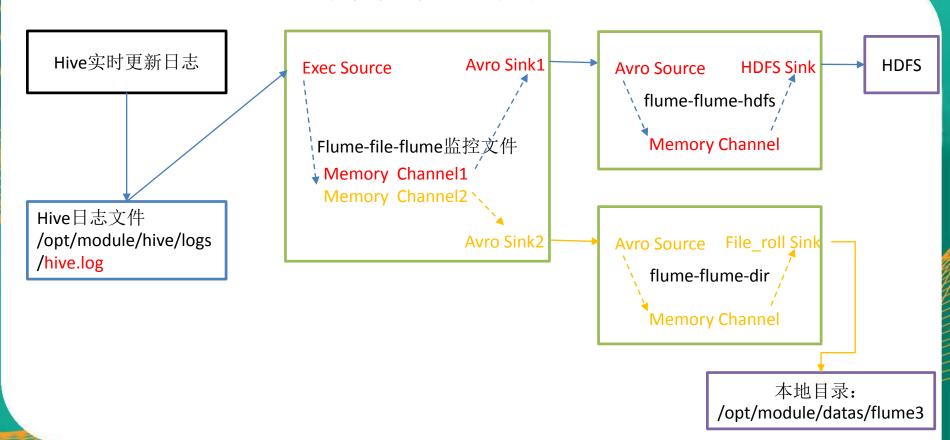


实时读取目录文件到HDFS案例

```
a3. sources = r3
                      #定义source
                                                            a3. sinks. k3. hdfs. rollInterval = 600 #多久生成新文件
                                                            a3. sinks. k3. hdfs. rollSize = 134217700 #多大生成新文件
                      #定义sink
a3. sinks = k3
                                                            a3. sinks. k3. hdfs. rollCount = 0 #多少event生成新文件
a3. channels = c3
                      #定义channel
                                                            a3. sinks. k3. hdfs. minBlockReplicas = 1 #多少副本数
# Describe/configure the source
a3. sources. r3. type = spooldir #定义source类型为目录
                                                            # Use a channel which buffers events in memory
a3. sources. r3. spoolDir = /opt/module/flume/upload #定义监控目录 a3. channels. c3. type = memory
a3. sources. r3. fileSuffix = . COMPLETED #定义文件上传完,后缀
                                                            a3. channels. c3. capacity = 1000
a3. sources. r3. fileHeader = true #是否有文件头
                                                            a3. channels. c3. transactionCapacity = 100
a3. sources. r3. ignorePattern = ([^ ]*\. tmp)
                          #忽略所有以. tmp结尾的文件,不上传
                                                           # Bind the source and sink to the channel
# Describe the sink
                                                            a3. sources, r3. channels = c3
                         #sink类型为hdfs
a3. sinks. k3. type = hdfs
                                                            a3. sinks. k3. channel = c3
a3. sinks. k3. hdfs. path
hdfs://hadoop102:9000/flume/upload/%Y%m%d/%H #文件上传到hdfs的路径
a3. sinks. k3. hdfs. filePrefix = upload-
                                       #上传文件到hdfs的前缀
                                       #是否按时间滚动文件
a3. sinks, k3. hdfs, round = true
a3. sinks. k3. hdfs. roundValue = 1
                                      #多少时间单位创建一个新的文件夹
                                       #重新定义时间单位
a3. sinks. k3. hdfs. roundUnit = hour
a3. sinks. k3. hdfs. useLocalTimeStamp = true #是否使用本地时间戳
                                       #积攒多少个Event才flush到HDFS一次
a3. sinks, k3. hdfs, batchSize = 100
a3. sinks.k3.hdfs.fileTvpe = DataStream
                                       #设置文件类型,可支持压缩
```



单数据源多出口案例





多数据源汇总案例

Hive实时更新日志

Hive日志文件 /opt/module/hive/logs /hive.log Exec Source Avro Sink
Flume-file-flume监控文件
Memory Channel

主机4444端口

通过telnet向44444端 口发送数据 Netcat Source Avro Sink Flume-telnet-flume监控文件 Memory Channel

Avro Source HDFS Sink HDFS
flume-flume-hdfs
Memory Channel



谢谢!欢迎收看